

# 確率と最適化

—関数近似と回帰—

# 今回の目標

- ▶ 関数近似問題を勾配法を利用して解く

関数近似問題は、機械学習における「回帰の問題」に直接つながる。また、ニューラルネットの学習も一種の関数近似問題と捉えることができる。

# 勾配法

## 制約無し最適化問題

$$\text{minimize}_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad (1)$$

### 勾配法のステップ

Step 1 (初期点設定)  $\mathbf{x} := \mathbf{x}_0$

Step 2 (勾配の計算)  $\mathbf{g} := \nabla f(\mathbf{x})$

Step 3 (探索点更新)  $\mathbf{x} := \mathbf{x} - \alpha \mathbf{g}$

Step 4 (反復) Step 2 に戻る

(注)

- ▶  $\alpha$  は探索係数 (実数)
- ▶ 探索点更新において直線探索を行う勾配法もある。

## 勾配法（雛形プログラム）

```
# -*- coding: utf-8 -*-  
import numpy as np  
#  $y = x^2 + y^2$  を目的関数とする。  
def grad(x):  
    return 2.0*x  
xt = np.array([5,5])  
alpha = 0.05  
for i in range(100):  
    xt = xt - alpha*grad(xt)  
    print "step=", i, xt  
    print
```

# 勾配


# 初期点

# ステップ係数

# メインループ

## 最小化の軌跡

$$f(x) = \frac{1}{2}x_0^2 + 5x_1^2, \quad \mathbf{x}_0 = (4, 1)^T, \alpha = 0.18$$



# 関数近似問題の問題設定

訓練集合:  $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}, \quad \{t_1, t_2, \dots, t_N\}$

$$\mathbf{x}_i \in \mathbb{R}^n (i = 1, 2, \dots, N), \quad t_i \in \mathbb{R} (i = 1, 2, \dots, N)$$

データ点とそれに対応する観測値があるとき、データにフィットする関数を探したい！

## 関数近似問題のざっくりとした定義

与えられた訓練集合に対して、パラメータ付き関数  $f(\mathbf{x}|\mathbf{w})$  を利用して、すべての  $i$  で

$$t_i \simeq f(\mathbf{x}_i|\mathbf{w})$$

となるような  $\mathbf{w}^*$  を求めたい。

## 回帰予測

訓練集合に含まれない未知の  $\mathbf{x} \in \mathbb{R}^n$  がやってきたとき、

$$\hat{t} = f(\mathbf{x}|\mathbf{w}^*)$$


として予測を行う。

## 訓練集合

訓練集合:  $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}, \quad \{t_1, t_2, \dots, t_N\}$

$$\mathbf{x}_i \in \mathbb{R} (i = 1, 2, \dots, N)$$

$$t_i \in \mathbb{R} (i = 1, 2, \dots, N)$$




# パラメータ付き関数の例

パラメータ付き関数の例として、

$$f(x|w) = wx$$

を考えよう。



もっともデータにフィットする  $w$  の選び方とは？



# 誤差関数

「関数近似問題のざっくりとした定義」  $t_i \simeq f(\mathbf{x}_i|\mathbf{w})$  に含まれている  $\simeq$  の意味を明確にしないと先に進めない。

## 2 乗和誤差関数

2 乗誤差を基準として

$$E(\mathbf{w}) = \frac{1}{2} \sum_{i=1}^N (f(\mathbf{x}_i|\mathbf{w}) - t_i)^2$$

と定義する。

## 2 乗和誤差関数に基づく関数近似問題

与えられた訓練集合  $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ ,  $\{t_1, t_2, \dots, t_N\}$  に対して、2 乗和誤差関数  $E(\mathbf{w})$  を最小化せよ。

## 練習問題

訓練集合として、 $\{x_1 = 1, x_2 = 2\}, \{t_1 = 2.2, t_2 = 3.8\}$  が与えられた。パラメータ付き関数モデルとしては、 $f(x|w) = wx$ (傾き  $w$  の直線) を利用する。次の問いに答えよ。

- (1) 2乗和誤差関数  $E(w)$  を書け。
- (2) 2乗和誤差関数  $E(w)$  の勾配 (gradient) を求めよ。
- (3) 勾配法のステップを実行してみよ。ただし、 $w$  の初期値は 0、 $\alpha = 0.1$  とする。反復3回目までの計算を行え (電卓利用可)。

## 練習問題の解答

(1)

$$E(w) = \frac{1}{2}(wx_1 - t_1)^2 + \frac{1}{2}(wx_2 - t_2)^2 \quad (2)$$

$$= \frac{1}{2}(w - 2.2)^2 + \frac{1}{2}(2w - 3.8)^2 \quad (3)$$

(2)

$$\frac{\partial E(w)}{\partial w} = (w - 2.2) + 2(2w - 3.8) \quad (4)$$

$$= 5w - 9.8 \quad (5)$$

※普通だったら、ここで極値条件から直接  $w$  を解くことになる  
( $E(w)$  は  $w$  に関して二次関数であり、下に凸であることが分かっている  
ので「極値＝最小値」が保証される→  $w^* = 1.96$ )。

## 練習問題の解答

(3) 問題より、初期値は  $w_0 = 0.0$  であり、 $\alpha = 0.1$  である。また、

$$g(w) = \frac{\partial E(w)}{\partial w} = 5w - 9.8$$

とおく。勾配法の反復計算過程は次のとおり。

(反復 1 回目)  $g(0.0) = -9.8$ ;  $w := 0.0 - 0.1(-9.8) = 0.98$

(反復 2 回目)  $g(0.98) = -4.9$ ;  $w := 0.98 - 0.1(-4.9) = 1.47$

(反復 3 回目)  $g(1.47) = -2.45$ ;  $w := 1.47 - 0.1(-2.45) = 1.715$


# パラメータ付き関数 $f(\mathbf{x}|\mathbf{w})$ の選択 (1)

## 多項式モデル

$x \in \mathbb{R}$

$$f(x|\mathbf{w}) = w_0 + w_1x + w_2x^2 + \cdots + w_Mx^M$$

$M$  をこの多項式モデルの次数と呼ぶ。



3 次関数モデルによるフィッティング

## パラメータ付き関数 $f(\mathbf{x}|\mathbf{w})$ の選択 (2)

### 正弦波重ね合わせモデル

$$f(x|\mathbf{w}) = w_0 + w_1 \sin(\omega x) + w_2 \sin(2\omega x) + \cdots + w_M \sin(M\omega x), \quad x \in \mathbb{R}$$

( $\omega$  は与えられた定数)

### 線形回帰モデル

$$f(\mathbf{x}|\mathbf{w}) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_M x_M, \quad \mathbf{x} = (x_1, \dots, x_M) \in \mathbb{R}^M$$

## 練習問題

線形回帰モデル ( $w_0$  としている)

$$f(\mathbf{x}|\mathbf{w}) = w_1 x_1 + w_2 x_2$$

を考える。訓練集合は

$$\mathbf{x}_1 = (1, 2), t_1 = 4 \quad (6)$$

$$\mathbf{x}_2 = (3, 1), t_2 = 2 \quad (7)$$

と与えられている。次の問いに答えよ。

- (1) 誤差関数のヘッセ行列が正定値であることを示せ。
- (2) 解析的に  $w^*$  を求めよ (すなわち、勾配法は利用しない)。

## 練習問題解答

(1) 誤差関数  $E(w_1, w_2)$  は

$$E(w_1, w_2) = \frac{1}{2}(w_1 + 2w_2 - 4)^2 + \frac{1}{2}(3w_1 + w_2 - 2)^2$$

と与えられる。この関数を  $w_1, w_2$  でそれぞれ偏微分すると

$$\frac{\partial E}{\partial w_1} = 10w_1 + 5w_2 - 10 \quad (8)$$

$$\frac{\partial E}{\partial w_2} = 5w_1 + 5w_2 - 10 \quad (9)$$

を得る。さらにヘッセ行列は、

$$\begin{pmatrix} 10 & 5 \\ 5 & 5 \end{pmatrix}$$

となる。



# 練習問題解答

## 2 次形式

$$(a, b) \begin{pmatrix} 10 & 5 \\ 5 & 5 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = 10a^2 + 10ab + 5b^2 \quad (10)$$

$$= 5a^2 + 5(a + b)^2 \quad (11)$$

は任意のゼロではない  $a, b \in \mathbb{R}$  に対して、正の値を持つ。したがって、このヘッセ行列は正定値行列であり、 $E(w_1, w_2)$  は下に凸 (convex) である。

(2) この誤差関数は下に凸な関数であることがわかったので、極値条件を満たす点が最小値を与える。極値条件  $\nabla E(w_1, w_2) = 0$

$$\frac{\partial E}{\partial w_1} = 10w_1 + 5w_2 - 10 = 0 \quad (12)$$

$$\frac{\partial E}{\partial w_2} = 5w_1 + 5w_2 - 10 = 0 \quad (13)$$

を解くことにより  $w_1^* = 0, w_2^* = 2$  を得る。

# 回帰フレームワークはどんなところで有用か？

例えば、興味のある対象について、過去のデータから将来の観測値を予測する、という使い方ある。

## 例 1: 株価予測

**訓練集合** 第  $i$  日の円ドル為替レート、第  $i$  日の  $X$  社の株価、  
そのほか経済指標  
→

**予測目標** 将来ある時点での  $X$  社の株価

## 例 2: 自動車事故率 (保険会社の視点から)

**訓練集合** 契約者の年齢、過去の事故歴、車種→

**予測目標** 将来のある人の事故率

# 回帰のためのレシピ

